
4STA2 – Projet d’analyse de série chronologique

Tirs de 3 points en NBA

Leto Van Ruymbeke - Laura Sánchez García-Romeu

3 Mars 2026

Table des matières

1	Introduction	1
2	Données	1
2.1	Contenu du jeu de données	1
2.2	Prétraitement et mise en forme des données	1
3	Analyse descriptive des données	2
4	Modélisation et prévision	2
4.1	Tendance	2
4.1.1	Analyse de la tendance par moyenne mobile	2
4.1.2	Analyse de la tendance par GAM	2
4.2	Cycles	4
4.2.1	Cyclicité annuelle	4
4.2.2	Cyclicité quotidienne ou auto-régression d’ordre 1	6
4.2.3	Cyclicité hebdomadaire ou auto-régression d’ordre 7	6
4.2.4	Supression du saut de saison dans le lag d’ordre 1	6
4.3	ARIMA	7
4.4	Partie aléatoire	8
4.5	Modèle final	8
5	Simulations de prévision	8
5.1	Évaluation des performances	9
5.2	Analyse graphique	9
6	Conclusion	10

1 Introduction

Présentation du sujet

Pour ce projet, nous avons choisi d'étudier l'évolution des tentatives de 3 points en NBA. Nous comptons tous les tirs effectués, qu'ils soient réussis ou non.




FIGURE 1 – Points marqués selon la distance de tir au panier en basketball

L'objectif de ce projet est d'analyser les données afin de détecter d'éventuelles tendances ou cycles, et d'élaborer un modèle prédictif que nous confronterons aux données réelles.

2 Données

2.1 Contenu du jeu de données

Le dataset NBA Database sur Kaggle couvre l'intégralité de l'histoire de la NBA, de la saison inaugurale 1946-1947 jusqu'à aujourd'hui. En particulier, nous avons utilisé le fichier `game.csv`.

2.2 Prétraitement et mise en forme des données

Le jeu de données initial est dense, donc nous avons nettoyé les données en supprimant les colonnes inutiles ou redondantes. Nous avons ensuite regroupé les tirs par date pour obtenir une série chronologique propre du taux de réussite quotidien.

Un premier coup d'œil aux tirs de 3 points renseignés permet de voir beaucoup de cases NA ou 0. On trouve le 3 février 1980 comme date à partir de laquelle les 3 points sont comptés dans notre dataset, on retire donc toutes les dates précédentes.

Comme plusieurs matchs peuvent avoir lieu le même jour et que les horaires ne sont pas renseignés, nous avons rassemblé les données par date pour calculer une moyenne journalière de tentatives (`mean_3pa`).

3 Analyse descriptive des données




FIGURE 2 – Visualisation des données initiales

On constate tout d'abord l'évolution fulgurante du nombre de 3 points tentés par match à partir de la saison 2009-2010, qui correspond notamment à l'arrivée de Stephen Curry en NBA, joueur connu pour son efficacité exceptionnelle à 3 points (43% de précision contre 35% pour la moyenne des joueurs de la NBA).

Nous voyons également une bosse entre 1995-1997, due à une modification des règles qui rapprochait la ligne des 3 points du panier. La ligne a ensuite été reculée à sa distance originelle. Ces données représentent donc une anomalie que le modèle ne devra pas apprendre, puisque ça ne se reproduira plus.

Enfin, les dernières données entre 2020 et 2024 montrent une légère diminution du nombre de 3 points essayés. Notre modèle pourra essayer de deviner si cette tendance à la baisse va continuer.

4 Modélisation et prévision

4.1 Tendence

4.1.1 Analyse de la tendance par moyenne mobile

Pour isoler la tendance de fond du "bruit" généré par l'irrégularité quotidienne des matchs, nous avons d'abord testé la méthode de la moyenne mobile avec différentes fenêtres temporelles (180 jours, 365 jours et 5 ans). L'objectif était de lisser la série temporelle pour rendre plus lisible l'évolution globale du tir à trois points. Cependant, nous avons rencontré quelques difficultés :

Avec des fenêtres courtes, la courbe reste trop proche des données et apprend des anomalies comme la "bosse" de 1995-1997, ce qui risque de fausser les prédictions. À l'inverse, une fenêtre trop longue lisse excessivement la série et entraîne une perte de données aux extrémités, nous empêchant d'analyser les saisons les plus récentes. Pour éviter ces problèmes et obtenir une courbe plus flexible, nous avons choisi d'utiliser un modèle GAM.

4.1.2 Analyse de la tendance par GAM

Initialement, nous autorisons jusqu'à $k=30$ degrés de liberté, en espérant affiner plus tard. Le modèle retient 26 degrés de liberté, soit une transition de la courbe toutes les saisons et demie. Ceci semble excessif et prend sûrement aussi en compte la saisonnalité, alors que nous cherchons la tendance globale de la courbe.




FIGURE 3 – Modèles GAM à différents degrés de liberté confrontés à la série temporelle

Comme attendu, 26 degrés de liberté est bien trop grand : on perd l'intérêt de remplacer la moyenne mobile par GAM puisqu'on retrouve une courbe en escalier qui suit les variations saisonnières. Nous testons alors des degrés de liberté k plus petits.




FIGURE 4 – Évolution du GCV selon le nombre de degrés de liberté autorisés

En raison de la forte corrélation entre le nombre de 3 points d'un jour j et celui de la veille, le GCV est d'autant plus bas que k est grand. Cela ne signifie pas pour autant qu'une bonne tendance est donnée par un modèle GAM avec un grand k .

Validation croisée par bloc du modèle GAM

Comme on n'arrive pas à choisir une valeur de k pour le modèle GAM par simple observation des courbes, on va tester pour k allant de 3 à 15, la qualité des prédictions sur un critère de validation croisée par bloc.




FIGURE 5 – Tendence du modèle GAM($k=4$) superposée aux données

En somme, minimiser le risque quadratique demande de limiter la flexibilité du modèle, quitte à ignorer la bosse anormale de 1995 à 2000, pour éviter le sur-apprentissage.

4.2 Cycles





FIGURE 6 – ACF et PACF du modèle GAM retenu ($k_{final} = 4$)

Ces 2 diagrammes montrent qu'un autre phénomène que la tendance intervient dans la dépendance entre les données sur le court terme. Sur l'ACF Figure 6, on observe plusieurs autocorrélations significatives pour des retards courts, ce qui indique que les valeurs proches dans le temps restent corrélées. Autrement dit, le nombre de tirs à 3 points tentés un jour donné dépend encore partiellement de celui des jours précédents. En pratique, on pourrait s'attendre par exemple à ce qu'un joueur qui a bien réussi ses tirs à un jour j , essaye davantage les quelques jours suivants.


Une autre hypothèse serait l'existence de cycles liés au calendrier de la saison NBA. Une saison s'étend sur plusieurs mois, avec des périodes d'intensité différente. Les équipes semblent souvent expérimenter davantage de tirs à trois points en début de saison, puis adopter des stratégies plus conservatrices en fin de saison, à l'approche des play-offs. Si un tel phénomène existe, on pourrait observer une corrélation entre des périodes similaires d'une saison à l'autre.

4.2.1 Cyclicité annuelle


Afin de tester cette deuxième hypothèse, nous essayerons d'abord d'identifier de potentiels cycles entre les saisons NBA, où les "shoot" d'un jour donné dépendent beaucoup du même jour, la saison précédente.




(a) Plot du modèle cyclique annuel avec $k = 4$



(b) Plot du modèle cyclique annuel avec $k = 10$



(c) ACF du modèle cyclique annuel avec $k = 4$



(d) ACF du modèle cyclique annuel avec $k = 10$

FIGURE 7 – Profil de modèles à cyclicité annuelle à $k = 4$ et $k = 10$ degrés de liberté

Nous avons cherché à voir si le taux de réussite suivait un cycle annuel, mais les tests (ACF/PACF) ne montrent aucune répétition de ce type. En forçant un modèle GAM à créer un cycle, on s'aperçoit qu'il "invente" une courbe dans le vide durant l'été pour relier artificiellement la fin d'une saison au début de la suivante. Ce cycle annuel est donc une illusion visuelle : en réalité, les performances ne dépendent pas du mois de l'année.

Echec du modèle à 4 degrés de liberté

Premièrement, la Figure 7 (a) témoigne de l'échec du modèle avec $k = 4$ degrés de liberté autorisés (3 edf retenus par le modèle) puisque le modèle ne trouve pas de motif cyclique assez fort et dessine une ligne quasi-horizontale. L'effet mensuel est "écrasé" par la tendance.

Echec du modèle à 10 degrés de liberté

En forçant un modèle GAM à créer un cycle, la Figure 7 (b) montre une oscillation durant l'été pour relier artificiellement la fin d'une saison au début de la suivante, à cause de la contrainte `bs='cc'`.

Echec du modèle cyclique annuel

Les graphiques (c) et (d) montrent des barres qui restent largement au-dessus du seuil de significativité pour presque tous les lags.

En somme, le cycle annuel est une illusion et la persistance des pics dans l'ACF et PACF prouve que la dynamique des tirs à 3 points est régie par une tendance lourde et une corrélation jour après jour, plutôt que par une variation systématique selon le mois de l'année.

4.2.2 Cyclicité quotidienne ou auto-régression d'ordre 1




FIGURE 8 – ACF et PACF du modèle auto-régressif d'ordre 1

Tout d'abord, on observe une baisse nette de la hauteur du plateau qu'on observait déjà sur l'ACF de modele_final. De plus, la PACF paraît converger relativement vite vers 0 : nous sommes en bonne voie.

Cependant, la persistance du plateau de l'ACF indique que l'auto-régressif d'ordre 1 ne suffit pas à décrire les données, bien qu'il fasse partie de la dépendance temporelle. On va se tourner vers l'analyse d'un potentiel cycle hebdomadaire en NBA, qui serait dû à une programmation favorisant les matchs importants les week-ends.

4.2.3 Cyclicité hebdomadaire ou auto-régression d'ordre 7

Le plateau de l'ACF est encore plus élevé que pour le modèle auto-régressif d'ordre 1. On abandonne l'idée d'une auto-régression d'ordre 7.

Pour le moment, le lag d'un jour (auto-régressif d'ordre 1) est le modèle qui explique le mieux la dépendance temporelle des données. Le problème, c'est qu'un lag de 1 fait que, dans le cas particulier du premier jour d'une saison s , on regarde le dernier jour de la saison $s-1$. Or, ces deux jours n'ont aucune raison d'être corrélés !

4.2.4 Suppression du saut de saison dans le lag d'ordre 1

Pour pallier cela, nous allons empêcher GAM de considérer le "jour précédent" lorsqu'il considère le premier jour d'une nouvelle saison. Cette étape est cruciale pour assurer la justesse mathématique de notre auto-régression d'ordre 1, mais elle ne permet pas d'améliorer nos ACF et PACF.




FIGURE 9 – ACF et PACF du nouveau modèle auto-régressif d'ordre 1

Encore une fois, le plateau persiste au-dessus du seuil de significativité, donc il reste bien un autre phénomène sous-jacent..

Une possibilité est que les résidus restent temporellement très corrélés d'un jour à l'autre à cause de la bosse de 1994 à 1997 visible sur nos données. Nous avons fait le choix d'une tendance qui ignore cette bosse, car elle est exogène, due à un changement de règle en NBA qui a ensuite été retirée. Nous allons "expliquer" à notre modèle que certaines saisons sont exceptionnelles à l'aide d'une variable booléenne.




FIGURE 10 – ACF et PACF du nouveau modèle auto-régressif d'ordre 1

On a encore ce plateau sur l'ACF qui implique que la prise en compte de cette bosse, la tendance et l'auto-régression d'ordre 1 ne suffisent pas à décrire nos données. Le modèle recherché est plus complexe.

4.3 ARIMA

On peut voir sur la Figure 10 que la pacf met trop longtemps à converger vers 0 pour considérer un certain ordre p pour le modèle AR. Nous calculerons différents modèles ARMA pour différentes valeurs de p et $q \leq 5$ afin de choisir celui qui minimise le AIC et le BIC, des coefficients, favorisant la précision d'un modèle en pénalisant les trop grandes valeurs de p et de q .

Nous utilisons 'apply' pour appliquer la fonction ARIMA ligne par ligne sur les résidus de notre modèle, selon les méthodes choisies, comme lors du TD6 vu en cours.

Après calcul de l'AIC pour chaque modèle ARMA(p,q), on obtient $p = 4$ et $q = 3$.




FIGURE 11 – ACF et PACF du modèle ARIMA(3,4) avec critère AIC

Visuellement, les corrélations temporelles de nos données ont été absorbées. L'ACF n'est qu'une barre verticale à 0 et le plateau qui subsistait sur les ordres supérieurs a disparu. Pour la PACF, on dirait bien celle d'un bruit blanc.

4.4 Partie aléatoire

Il faut maintenant démontrer proprement qu'il ne reste plus de dépendance à d'autres phénomènes.

Test de Box-Pierce

Malheureusement, le modèle n'est pas indépendant à 5% près, car la $pvalue = 0.02924386 < 5\%$.

Le modèle ARIMA par critère BIC nous donne des courbes similaires à Figure 11, mais malheureusement la $pvalue = 0.01191692 < 5\%$ ne valide pas non plus le critère de Box-Pierce.

Modèle ARMA

Les premiers modèles ARMA testés à l'aide des critères AIC et BIC donnaient des résultats visuellement satisfaisants. Cependant, aucun des quatre meilleurs modèles selon ces critères ne passait le test de Box-Pierce au seuil de 5%.

Autrement dit, même si les ACF et PACF semblaient indiquer un bruit blanc, le test statistique révélait qu'il restait encore de la dépendance temporelle dans les résidus.

Nous avons donc décidé de parcourir les modèles ARMA par ordre croissant d'AIC et de BIC, appliquer le test de Box-Pierce à chacun d'entre eux et retenir le premier modèle dont la p-value dépasse 5%.

Malheureusement, pour des valeurs de p et q limitées à 5, aucun modèle ne validait ce critère. Nous avons augmenté la valeur maximale de p à 10. Cela augmente considérablement le nombre de modèles à tester et le temps de calcul. Après recalcul des modèles ARMA, le meilleur modèle selon l'AIC devient : ARMA(8,1)

Test de Box-Pierce

Le test de Box-Pierce appliqué aux résidus de ce modèle donne : $pvalue = 0.06$. Le modèle est satisfaisant.

4.5 Modèle final

Le modèle obtenu : $Y_t = Tendance + Bosse_{94-97} + ARMA(8,1) + \epsilon_t$ est cohérent avec la réalité sportive : les stratégies offensives d'une équipe peuvent évoluer sur plusieurs matches consécutifs. Nous voyons que les 8 jours précédents influencent encore légèrement la valeur du jour, le bruit aléatoire de la veille intervient également via la composante MA(1).

Il reste à vérifier quels coefficients du modèle ARMA sont réellement pertinents, donc nous avons étudié la significativité statistique des paramètres à l'aide d'un test de Wald.

Les résultats montrent que $\phi_1, \phi_2, \phi_3, \phi_8, \theta_1$ sont significatifs. Afin d'éviter un sur-apprentissage, nous avons donc testé une version contrainte du modèle où $\phi_7 = 0$, qui passe effectivement le test de Box-Pierce avec 0.06285651.

En revanche, si l'on force d'autres coefficients non significatifs à zéro, le modèle ne passe plus le test d'indépendance. Nous retenons donc le modèle final ARMA(8,1) avec $\phi_7 = 0$

5 Simulations de prévision

Nous testons ensuite le modèle sur une saison NBA récente (2023-2024) récupérée via l'API hoopR, que nous avons correctement mis en forme. Pour effectuer des prédictions, nous additionnons $Prevision = Tendance(GAM) + ARMA$.

5.1 Évaluation des performances

Afin de mesurer la qualité des prévisions, nous calculons les deux indicateurs classiques RMSE d'environ 1.45 tirs et MAE de 1.45 tirs. Autrement dit, en moyenne, l'erreur de prévision est d'environ 1.45 tentative de tir à trois points par jour.

Aujourd'hui, les équipes NBA tentent en moyenne près de 40 tirs à trois points par match. Une erreur moyenne d'environ 1.45 tirs correspond donc à une précision proche de 96%. Le modèle semble donc capable de prédire correctement l'évolution globale du nombre de tirs à trois points sur une saison complète.

5.2 Analyse graphique




FIGURE 12 – Visualisation finale

Ce tracé récapitule l'ensemble du projet. On y retrouve les données réelles (en vert) superposées à nos différentes tentatives : la tendance globale GAM (bleu), la version incluant la « bosse » historique (violet), et enfin notre modèle complet (rouge) combinant la tendance, la bosse et un modèle ARMA(8,1). Nous constatons visuellement la précision de l'ajustement. La courbe du modèle suit fidèlement les évolutions du taux de réussite quotidien.




FIGURE 13 – Prévisions sur des données réelles

Sur ce graphique, les données réelles de 2023-2024 apparaissent en vert et notre prédiction en rouge. La courbe rouge est beaucoup plus régulière que la verte car le modèle prédit la tendance et les cycles, pas l'aléa pur d'un match précis. Ce qui est très satisfaisant, c'est qu'il n'y a ni sur-estimation ni sous-estimation systématique, ce qui prouve que nous avons évité le sur-apprentissage. En regardant l'axe des

ordonnées, on remarque que l'écart ne dépasse jamais 2 tirs à trois points sur une moyenne de 37 : notre modèle est donc extrêmement précis.




FIGURE 14 – Validation finale des résidus

Ce test montre que nos résidus forment bien un bruit blanc. La courbe dessine une belle gaussienne, confirmant que l'erreur est répartie par pur hasard. De plus, aucune barre ne dépasse les pointillés bleus de façon significative. La p-value obtenue est de $0.25 > 0.05$. On peut donc affirmer avec une confiance de plus de 95% que les résidus sont bien un bruit blanc.

6 Conclusion

Dans ce projet, nous avons étudié l'évolution du nombre de tentatives de tirs à trois points en NBA à l'aide de méthodes d'analyse de séries temporelles. Nous avons réussi à modéliser le taux de réussite à 3 points en NBA en extrayant chaque couche d'information : la tendance de fond, les anomalies historiques et les cycles de jeu. Ce qu'il reste (l'aléa) n'est plus modélisable statistiquement : le bruit blanc est la part d'imprévisibilité propre au sport. Enfin, cette étude illustre bien l'évolution stratégique du basketball moderne : le tir à trois points occupe aujourd'hui une place centrale dans le jeu, et son évolution peut être décrite avec succès par des modèles statistiques de séries temporelles.